


Introduction à la Reconnaissance de formes Statistiques

Schéma général



→ On a $\bar{x} \in \mathbb{R}^m$, $\bar{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix}$, $\exists M$ classes w_1, w_2, \dots, w_M

Objectif: Déterminer dans quelle classe range \bar{x}


cas : À partir de $\bar{x} \Rightarrow$ Quelle classe lui attribuer

Méthodes déterministes

$$\bar{x} \in S \subset \mathbb{R}^m$$

$$\bigcup_{m=1}^M R_m = S \quad (\text{exhaustivité})$$

$$R_i \cap R_j = \emptyset \quad \text{ni ito} \quad (\text{non-ambiguité})$$



$$\bar{x} \in R_m \Leftrightarrow \bar{x} \text{ est dans la classe } w_m$$

Voc : $M = 2 \rightarrow$ "Détection"

$M > 2$ | $\begin{cases} \text{mois connu} \rightarrow \text{"Discriminat"} \\ \text{mois inconnu} \rightarrow \text{"Classificat"} \end{cases}$

I. Méthodes Linéaires de Discrimination

A/ Cas à $M = 2$ classes

→ Problématique : On a 2 bases d'exemples pour l'apprentissage

$$\mathcal{B}_{M_1} = \{\bar{x}^i \mid \bar{x}^i \in \mathcal{W}_1\} \quad \mathcal{B}_A = \mathcal{B}_{M_1} \cup \mathcal{B}_{M_2}$$


$$\mathcal{B}_{M_2} = \{\bar{x}^i \mid \bar{x}^i \in \mathcal{W}_2\}$$

$$\text{à chaque } \bar{x}^i \in \mathcal{B}_A \longrightarrow d^i = \begin{cases} +1 & \text{si } \bar{x}^i \in \mathcal{W}_1 \\ -1 & \text{si } \bar{x}^i \in \mathcal{W}_2 \end{cases}$$

Objectif de la DL : déterminer un vecteur $\bar{w} \in \mathbb{R}^N$ tq :

$$\bar{w}^T \bar{x} + w_0 > 0 \quad \text{si } \bar{x} \in \mathcal{W}_1 \\ \leq 0 \quad \text{si } \bar{x} \in \mathcal{W}_2$$

$$\bar{w}^T \bar{x} = \sum_i w_i x_i = \text{produit scalaire entre } \bar{w} \text{ et } \bar{x}$$



$$\bar{w}^T \bar{x} + w_0 = 0 : \text{Eq d'un Hyperplan. Notons } \bar{w}' = \begin{pmatrix} w_0 \\ \vdots \\ w_N \end{pmatrix}, \bar{x}' = \begin{pmatrix} 1 \\ x_1 \\ \vdots \\ x_N \end{pmatrix} \\ \Rightarrow \bar{w}' \bar{x}' + w_0 = \bar{w}' \bar{x}' \rightarrow \text{équation simple}$$

Dans la suite, on utilisera \bar{w}' et \bar{x}' sans moter les " " i.e. $\{\bar{w}' \bar{x}'\}$

Méthodologie générale : Base d'exemple $\xrightarrow{\text{B}_A \text{ apprendre}} \text{(taille } P_A)$ $\xrightarrow{\text{B}_B \text{ généraliser}} \text{(taille } P_B)$

B/ Méthode de Hell

$$\bar{w}_{Hell} = \sum_{i=1}^{P_A} \text{de } \bar{x}^i$$

\downarrow
 $\frac{+1}{-1}$

Caractéristiques des performances :

$$T_A \text{ d'apprentissage: } T_A = \frac{1}{P_A} \sum_{i=1}^{P_A} m_i$$

$$m_i = \begin{cases} 1 & \text{si } \text{sign}(\bar{w}' \bar{x}') = \text{sign}(d^i) \text{ i.e. bonne}\\ 0 & \text{sinon: Erreur} \end{cases}$$

$$T_B \text{ généralisation: } T_B = \frac{1}{P_B} \sum_{i=1}^{P_B} m_i$$

C/ Méthode de la Pseudo-Inverse

- Critère plus rigoureux : erreur quadratique

$$J = \sum_{i=1}^m [\bar{w}^T \bar{x}_i - \bar{d}_i]^2 = \|\bar{d} - \bar{X} \bar{w}\|^2 \quad \text{avec} \quad \begin{cases} \bar{d} = \begin{pmatrix} d_1 \\ d_2 \\ \vdots \\ d_m \end{pmatrix} \\ \bar{X} = \begin{pmatrix} 1 & x_1^T & x_2^T & \cdots & x_N^T \\ 1 & x_1^T & x_2^T & \cdots & x_N^T \end{pmatrix} \end{cases}$$

Objectif: Trouver \bar{w} qui minimise J

$$\begin{aligned} J &= [\bar{d} - \bar{X} \bar{w}] [\bar{d} - \bar{X} \bar{w}]^T = (\bar{d}^T \bar{d}) - \bar{d}^T \bar{X} \bar{w} - \bar{w}^T \bar{X}^T \bar{d} + \bar{w}^T \bar{X}^T \bar{X} \bar{w} \\ &= a - 2\bar{w}^T \bar{X}^T \bar{d} + \bar{w}^T \bar{X}^T \bar{X} \bar{w} \\ &= a - 2\bar{w}^T \bar{v} + \bar{w}^T \bar{M} \bar{w} = a - 2 \sum_{i=1}^{N+1} M_{ii} w_i + \sum_{i,j} M_{ij} w_i w_j \end{aligned}$$

$$\frac{\partial J}{\partial w_m} = -2v_m + \sum_i M_{mi} w_i + \sum_i M_{im} w_i \quad \text{on } M_{ij} := M_{ji} \text{ car } M^T = M$$

$(M = \bar{X}^T \bar{X})$

$$= -2v_m + 2 \sum_i M_{mi} w_i$$

$$\begin{aligned} \text{donc } \frac{\partial J}{\partial w_m} = 0 &\Leftrightarrow \sum_i M_{mi} w_i = v_m \quad \forall m \\ &\Leftrightarrow \bar{M} \bar{w} = \bar{v} \\ &\Leftrightarrow \bar{X}^T \bar{X} \bar{w} = \bar{X}^T \bar{d} \end{aligned}$$

Finalement, on cherche \bar{w} tq $\boxed{\bar{X}^T \bar{X} \bar{w} = \bar{X}^T \bar{d}}$

Solut°: * Cas 1: $X^T X$ est inversible. Alors $\bar{w} = \underbrace{(\bar{X}^T \bar{X})^{-1}}_{\bar{X}^T \bar{X} \text{ pseudo-inverse}} \bar{X}^T \bar{d}$

* Cas 2: $X^T X$ non inversible

$\bar{M} = \bar{X}^T \bar{X}$ est symétrique \Rightarrow diagonalisable

i.e. $\exists U$ normale ($U^T U = U U^T = \text{Id}$) tq $\bar{M} = U^T \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_m \end{pmatrix} U$


Soit n le rang de M . Si $n < N+1$, M non inversible (rang > rang de U = rang de U^T)

$$\bar{M} = U^T \begin{pmatrix} \lambda_1 & & & \\ & \ddots & & \\ & & \lambda_n & 0 \\ & & 0 & \ddots & 0 \end{pmatrix} U$$

Pseudo-inverse de M : $\bar{M}^{\text{PI}} = U^T \begin{pmatrix} 1/\lambda_1 & & & \\ & \ddots & & \\ & & 1/\lambda_n & 0 \\ & & 0 & \ddots & 0 \end{pmatrix} U$ On a bien $\bar{M}^{\text{PI}} = \bar{M}^{-1}$
si rang $n = N+1$

$$\bar{w} = (X^T X)^{-1} X^T d : \text{généralisé de la PI de } \bar{X}$$

Exemple: $N=2$



TP: Peut arriver quand $P_A \approx N$, il y a des pi très petit alors le cost J_0 très grand.

Soltz → Augmenter taux de sur du droit

D/ Limite de la PI

$$J = \sum_{e=1}^n (w^T x_e - d_e)^2$$

Il faudrait plutôt utiliser:

$$J = \sum_{e=1}^n |\text{sign}(w^T x_e) - d_e| \rightarrow \text{mais pas solt. analytique et pas stable}$$

Critère du Perceptron: $J_p = \sum_{e \in S_{\text{err}}} -d_e w^T x_e$, $S_{\text{err}} = \{e \text{ tq } d_e w^T x_e < 0\}$

d_{err} , $J_p \geq 0$ et $J_p = 0$ n'est pas erreur

Méthode Gradient: $\bar{w}^{k+1} = \bar{w}^k - \alpha(R) \vec{\nabla} J_p$

Algorithme du Perceptron → converge vers une solut° si B_A est linéairement séparable

Sinon: problèmes de convergence

Discriminant logistique (Cox: 1960)


$$g(m) = \frac{e^m}{1 + e^m}$$

Nouveau critère:

$$J_{DL} = \sum_{e=1}^n [d_e - g(\bar{w}^T \bar{x}_e)]^2$$

→ Fonct° J dérivable \Rightarrow Méthode de gradient pour trouver w

Autre écriture du \hat{m} type: $J_{RN} = \sum_{e=1}^n [d_e - \sigma(w^T x_e)]^2$ où $\sigma(n) = \frac{e^n - 1}{e^n + 1} = 2g(n) - 1$



Risque de maxima